

Departamento de Estadística y Matemáticas
Facultad de Ciencias Económicas
Estadística II
Parcial IV

Nombre: _____ Cédula: _____

1. En el estudio del desarrollo económico, la salud de la población ocupa un lugar central: no es únicamente un fin en sí mismo, sino también un componente esencial del capital humano que incide sobre la productividad, la acumulación de capital y el bienestar de largo plazo. Desde la clásica *curva de Preston*, que documentó la fuerte relación positiva entre el ingreso per cápita y la esperanza de vida (relación que se aplanan a medida que aumenta el ingreso), la economía de la salud ha buscado cuantificar cómo los recursos económicos, la educación, la inversión en inmunización y las condiciones epidemiológicas de un país se traducen en resultados de salud a escala nacional.

Persisten, sin embargo, profundas desigualdades entre países, en donde, mientras las economías desarrolladas superan los 80 años de esperanza de vida, numerosos países en desarrollo permanecen muy por debajo, condicionados por la mortalidad adulta e infantil, la carga de enfermedades como el VIH, y el rezago en escolaridad y cobertura de vacunación. Comprender los determinantes de estas brechas es indispensable para orientar la asignación de recursos públicos escasos y evaluar políticas de salud, educación e inmunización. En este contexto, los modelos de regresión constituyen la herramienta fundamental para cuantificar las relaciones entre los distintos factores demográficos, epidemiológicos, económicos y sociales que influyen sobre los resultados de salud y desarrollo.

Con el objetivo de analizar dichos determinantes, se dispone de una base de datos construida a partir del repositorio del **Global Health Observatory** de la Organización Mundial de la Salud (OMS), complementada con información económica de las Naciones Unidas, que cubre países de todo el mundo durante el período **2000-2015**. La base contiene información demográfica, epidemiológica, de inmunización, económica y social. El análisis de estos datos es crucial para economistas y planificadores de política pública, ya que permite entender la elasticidad de los resultados de salud respecto a múltiples determinantes, identificar países con mayor rezago, y evaluar el retorno de la inversión en salud y educación bajo diferentes contextos de desarrollo.

La base de datos contiene los siguientes campos:

Variables Categóricas:

- **Country:** Nombre del país
- **Status:** Estatus de desarrollo económico del país.
 - Developed (desarrollado)
 - Developing (en desarrollo)
- **Year:** Año de observación.
 - Rango: 2000-2015

Variables Numéricas:

- **Life_expectancy:** Esperanza de vida al nacer, en años.
 - Rango aprox.: 36 - 89 años
- **Adult_mortality:** Tasa de mortalidad adulta (probabilidad de morir entre los 15 y los 60 años), por cada 1,000 habitantes.

- Rango aprox.: 1 - 723
- **Infant_deaths**: Número de muertes de menores de 1 año.
 - Rango aprox.: 0 - 1,800
- **Under_five_deaths**: Número de muertes de menores de 5 años.
 - Rango aprox.: 0 - 2,500
- **Alcohol_consumption**: Consumo de alcohol registrado en litros de alcohol puro per cápita.
 - Rango aprox.: 0 - 18 litros
- **Percentage_expenditure**: Gasto en salud como porcentaje del PIB per cápita.
 - Rango aprox.: 0 - 19,480
- **Hepatitis_B**: Cobertura de inmunización contra la Hepatitis B en niños de 1 año.
 - Rango aprox.: 1 % - 99 %
- **Measles**: Número de casos de sarampión reportados.
 - Rango aprox.: 0 - 212,183
- **BMI**: Índice de masa corporal (IMC) promedio de la población adulta.
 - Rango aprox.: 1 - 87
- **Polio**: Cobertura de inmunización contra la poliomielitis en niños de 1 año.
 - Rango aprox.: 3 % - 99 %
- **Total_expenditure**: Gasto público en salud como porcentaje del gasto total del gobierno.
 - Rango aprox.: 0.4 % - 17.6 %
- **Diphtheria**: Cobertura de inmunización DTP3 (difteria) en niños de 1 año.
 - Rango aprox.: 2 % - 99 %
- **Incidents_HIV**: Muertes por VIH/SIDA por cada 1,000 nacidos vivos (0-4 años).
 - Rango aprox.: 0.1 - 50.6
- **GDP_per_capita**: Producto Interno Bruto per cápita, en USD corrientes.
 - Rango aprox.: 2 - 119,173 USD
- **Population**: Población total del país, en número de habitantes.
 - Rango aprox.: 34 - 1,293,859,294
- **Thinness_ten_nineteen_years**: Prevalencia de delgadez (bajo peso) en la población de 10-19 años.
 - Rango aprox.: 0.1 % - 27.7 %
- **Thinness_five_nine_years**: Prevalencia de delgadez (bajo peso) en la población de 5-9 años.
 - Rango aprox.: 0.1 % - 28.6 %
- **Income_composition**: Índice de composición de ingresos de los recursos (componente del IDH).
 - Rango aprox.: 0 - 0.948
- **Schooling**: Promedio de años de escolaridad.
 - Rango aprox.: 0 - 20.7 años

Filtros obligatorios. Antes de realizar cualquier análisis estadístico, debe aplicar **filtros sobre las DOS variables categóricas** para construir una subpoblación específica, en donde elija uno de los 2 posibles **Status** y seleccione entre 3 años diferentes de la variable **Year**. Usted selecciona los valores de cada filtro. **La misma subpoblación debe usarse en las Partes A y B.**

Nota: Recuerde que el operador **&** se usa para condicionales conjuntos (que cumpla ambas condiciones), y el **|** para condicionales desyuntos (que cumpla una condición, la otra condición o ambas), así que tenga cuidado al momento de hacer los filtros.

- a) **(0.5 puntos)** Si tuviera que plantear una regresión entre la **variables respuesta** *Schooling* (Y) y otras variables de la base de datos, qué 3 variables seleccionaría cómo **variables explicativas** X y por qué considera que estas variables podrían explicar el comportamiento de la variable respuesta Y .

- b) **(0.5 puntos)** De las 3 variables seleccionadas en el punto anterior, elija una para plantear una regresión lineal simple (modelo (I)) de la forma

$$Y = \beta_0 + \beta_1 X + \varepsilon \quad (I)$$

y elija las dos restantes para plantear una regresión lineal múltiple (modelo (II)) de la forma

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon \quad (II)$$

Justifique cómo esperaría usted que fuese el signo de los parámetros β_0 y β_1 en el caso del modelo (I) , y cómo esperaría que fuese el signo de los parámetros β_0 , β_1 y β_2 en el caso del modelo (II) .

- c) **(0.5 puntos)** Realice el cálculo de los estimadores para los parámetros β , tanto del modelo (I) como del modelo (II) e interprete éstos en el contexto de los datos. Los resultados obtenidos fueron consistentes con lo que esperaba en el inciso anterior?
- d) **(0.5 puntos)** Pruebe la significancia estadística de los parámetros β en ambos modelos, empleando para ello un nivel de significancia del 5 %, e interprete en el contexto de los datos.
- e) **(0.5 puntos)** Construya un intervalo de confianza para los parámetros β en ambos modelos, empleando para ello un nivel de confianza del 95 %, e interprete en el contexto de los datos.
- f) **(1 punto)** Verifique si se cumplen o no los supuestos del modelo de regresión lineal planteado en ambos modelos, e interprete los resultados.
- g) **(0.5 puntos)** Pruebe la significancia estadística de la regresión lineal planteada en ambos modelos, empleando para ello un nivel de significancia del 5 %, e interprete en el contexto de los datos.
- h) **(0.5 puntos)** Realice el cálculo del coeficiente de determinación R^2 asociado a la regresión lineal simple, y el $R^2_{ajustado}$ asociado a la regresión lineal múltiple, e interprete el resultado obtenido. Dicho resultado es consistente con lo que se concluyó en el inciso anterior?
- i) **(0.5 puntos)** Seleccione un valor para cada covariable x_i de los modelos entre los posibles que considera que puede tomar la variable que escogió como X , y con éste, construya un intervalo de predicción del 95 % para cada modelo (I) y (II) e interprete en el contexto de los datos.